

دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده مهندسی برق

پروژه نهایی

هوش مصنوعی جراحی

اتصال بینایی واقعی جراحی به کنترل در شبیه سازی

اطلاعات دانشجو

نام و نام خانوادگی	نیکي مهديان
شماره دانشجویی	401231539
تاریخ ارائه	تیرماه ۱۴۰۵

گزارش نهایی؛ بینایی ماشین و کنترل رباتیک جراحی

مخزن گیت هاب:

<https://github.com/nikimahdian/MachineVision-KNTU-SurgicalAI>



فهرست مطالب

۵	۱	چکیده
۵	۲	مقدمه
۵	۱.۲	زمینه و انگیزه
۵	۲.۲	اهداف پروژه
۶	۳.۲	دامنه و محدوده گزارش
۶	۴.۲	ساختار گزارش
۶	۳	بیان مسئله و معماری سامانه
۶	۱.۳	چرا ترکیب بینایی واقعی و شبیه‌سازی؟
۷	۲.۳	معماری سامانه
۷	۳.۳	اهداف و محدوده
۸	۴.۳	ساختار پوشه‌ها
۸	۴	بخش بینایی ماشین: داده، مدل و نتایج
۸	۱.۴	مجموعه داده CholecSeg8k
۹	۲.۴	مدل، آموزش و تنظیمات
۱۰	۳.۴	نتایج segmentation و تحلیل
۱۲	۵	بخش شبیه‌سازی و کنترل رباتیک
۱۲	۱.۵	محیط، وظیفه و کنترلرها
۱۴	۲.۵	تحلیل رفتار هر کنترلر
۱۵	۶	اتصال بینایی به کنترل: سیاست یادگرفته خودمان
۱۵	۷	پایپ‌لاین اجرا و پیاده‌سازی
۱۶	۸	نمونه‌های تصویری، ویدیو و تفسیر بصری
۱۶	۱.۸	نمونه داده و پیش‌بینی مدل
۱۷	۲.۸	فریم‌های واقعی از ویدیوهای شبیه‌سازی SOFA
۲۰	۹	راهنمای فارسی رنگ‌های ماسک
۲۲	۱۰	معیارها و روش ارزیابی



۲۳	۱۱	بحث و محدودیت‌ها
۲۳	۱.۱۱	تحلیل طراحی و انتخاب روش
۲۳	۱.۱.۱۱	دلیل انتخاب DeepLabV3+
۲۳	۲.۱.۱۱	دلیل کنترل قانون‌محور
۲۳	۲.۱۱	گسترش آینده
۲۳	۱۲	خروجی‌های تحویل
۲۳	۱.۱۲	فایل‌های کلیدی
۲۴	۱۳	جمع‌بندی و نتیجه‌گیری
۲۴	۱.۱۳	یافته‌های بخش بینایی
۲۴	۲.۱۳	یافته‌های بخش کنترل
۲۴	۳.۱۳	یافته‌های مسیر تصویر→اکشن
۲۴	۴.۱۳	دستاوردهای کلی
۲۵	آ	ضمیمه: خلاصه معیارها



فهرست تصاویر

۷	مسیر کلی پروژه از داده تا خروجی	۱
۹	توزیع پیکسل کلاس‌ها؛ نامتوازن بودن دلیل وزن‌دهی در تابع هزینه	۲
۱۱	IoU هر کلاس (مرتب‌شده)؛ کلاس‌های ساختاری قوی‌تر، کلاس‌های کم‌نمونه ضعیف‌تر	۳
۱۱	رابطه وزن کلاس و فراوانی پیکسل؛ وزن بالاتر برای کلاس‌های کم‌نمونه	۴
۱۲	چپ: روند loss آموزش؛ راست: روند mIoU/Dice روی آزمون	۵
۱۲	چپ: فراوانی پیکسل در برابر IoU؛ راست: Dice در برابر IoU هر کلاس	۶
۱۳	چپ: مقایسه نرخ موفقیت؛ راست: نمودار راداری نرمال‌شده کنترلرها	۷
۱۴	رابطه پاداش و طول اپیزود؛ oracle کوتاه‌تر و پاداش بهتر	۸
۱۶	نمونه‌های ground-truth: تصویر واقعی + ماسک مرجع	۹
۱۶	خروجی مدل: تصویر، ماسک مرجع و پیش‌بینی در کنار هم	۱۰
۱۷	نمونه دیگر overlay؛ خطا بیشتر در کلاس‌های باریک دیده می‌شود	۱۱
۱۷	مرجع oracle (دسترسی به state) میانه و انتها؛ موفقیت کامل	۱۲
۱۸	کنترلر heuristic با مختصات تقریبی: میانه و انتها؛ موفقیت کامل	۱۳
۱۸	سیاست خودمان bc_rgb_v2 (فقط RGB، بدون مختصات هدف): میانه و انتها؛ موفقیت کامل	۱۴
۱۹	همان bc_rgb_v2 روی سید ۷ (موقعیت شروع متفاوت): میانه و انتها	۱۵
۱۹	پایه منفی random: میانه و انتها؛ شکست (موفقیت صفر)	۱۶
۲۰	پل قدیمی (seg model_vision)→centroid→(velocity) میانه و انتها؛ شکست	۱۷



فهرست جداول

۸	نقش پوشه‌های اصلی پروژه	۱
۱۰	تنظیمات آموزش	۲
۱۳	نتایج کنترل TissueRetraction (پروتکل دفاع؛ اعداد قفل)	۳
۱۵	مراحل اجرا و نقاط ورود کد	۴
۲۱	فهرست ۱۳ کلاس معنایی (شناسه و معنی فارسی)	۵
۲۱	معنی رنگ‌ها در ماسک‌های معنایی	۶
۲۵	جدول یک‌جای نتایج	۷



۱ چکیده

خلاصه پروژه

این گزارش نتیجه یک پروژه کامل در حوزه «هوش مصنوعی جراحی» است که دو بخش اصلی دارد: بینایی ماشین روی تصاویر واقعی لاپاراسکوپی، و کنترل رباتیک در محیط شبیه‌سازی شده. در بخش اول، مدل DeepLabV3+ روی مجموعه داده CholecSeg8k آموزش دیده و segmentation معنایی ۱۳ کلاس انجام می‌دهد. در بخش دوم، وظیفه کشیدن بافت (tissue retraction) در SOFA با کنترلرهای قانون‌محور، پل بینایی، و Behavior Cloning از RGB ارزیابی شده است.

پروژه یک پایپ‌لاین قابل تکرار از «داده خام» تا «تحویل نهایی» پیاده‌سازی کرده است. مدل بخش‌بندی خودمان (run3_ft/DeepLabV3+) روی داده واقعی به $mIoU_{present}=0.526$ و $Dice=0.611$ رسیده است. سیاست کنترل یادگرفته خودمان (bc_rgb_v2) فقط از تصویر RGB، بدون مختصات هدف شبیه‌ساز، وظیفه TissueRetraction را با $success=1.000$ روی 5 سید $40 \times$ اپیزود انجام می‌دهد (Wilson 95% بازه [0.981, 1.000]) و با سقف oracle هم‌تراز است. روی سیدهای مختلف با موقعیت شروع متفاوت نیز پایدار عمل می‌کند.

نکات کلیدی

(۱) مدل segmentation خودمان روی داده واقعی جراحی قوی کار می‌کند. (۲) سیاست BC خودمان از RGB بدون مختصات هدف کنترل می‌کند. (۳) موفقیت کنترل 1.000 و هم‌سطح سقف oracle. (۴) روی شروع‌های متفاوت (سیدهای مختلف) پایدار است.

۲ مقدمه

۱.۲ زمینه و انگیزه

جراحی لاپاراسکوپی امروز یکی از رایج‌ترین روش‌های کم‌تهاجمی است. جراح از طریق چند سوراخ کوچک، با دوربین و ابزارهای بلند، عمل را انجام می‌دهد. در چنین محیطی، سیستم‌های کمک جراح مبتنی بر هوش مصنوعی می‌توانند به تفکیک بافت‌ها، هشدار درباره ساختارهای حساس (مثل مجاری صفراوی) و هدایت حرکت ابزار کمک کنند. اما ساخت چنین سیستمی دو چالش دارد. اول: دیتاست‌های واقعی جراحی معمولاً برچسب تصویری (ماسک) دارند، اما حرکت ابزار و پاداش کنترلی ندارند. دوم: شبیه‌سازهای فیزیکی (SOFA) امکان آزمایش کنترل را می‌دهند، اما تصویرشان با واقعیت اتاق عمل فرق دارد. این پروژه هر دو مسیر را جدا پیاده‌سازی و با Vision Bridge به هم وصل می‌کند.

۲.۲ اهداف پروژه

اهداف این پروژه در چهار سطح تعریف شده‌اند:

۱. هدف علمی: نشان دادن امکان یادگیری segmentation روی داده واقعی جراحی و ارزیابی کنترل در شبیه‌ساز.

۲. هدف فنی: ساخت پایپ‌لاین یکپارچه از دانلود داده تا تولید گزارش و ویدیو.



۳. هدف ارزیابی: مقایسه کنترلرها با معیارهای شفاف (success rate، پاداش، طول اپیزود).

۴. هدف تحویل: بسته کامل قابل ارائه شامل مدل، معیار، نمودار و توضیح فارسی.

۳.۲ دامنه و محدوده گزارش

این گزارش بر پیاده‌سازی و نتایج مدل‌های خودمان تمرکز دارد؛ نه بحث بالینی عمیق. بخش بینایی: DeepLabV3+ روی CholecSeg8k. بخش کنترل: سیاست یادگرفته RGB→اکشن در TissueRetractionEnv (sofa_env) که بدون مختصات هدف شبیه‌ساز کار می‌کند.

۴.۲ ساختار گزارش

گزارش به‌صورت زیر سازماندهی شده است:

- بخش ۲: بیان مسئله و معماری کلی سامانه
- بخش ۳: داده، مدل و نتایج بینایی
- بخش ۴: شبیه‌سازی، کنترلرها و نتایج
- بخش ۵: Vision Bridge
- بخش ۶: پایپ‌لاین اجرا
- بخش ۷: نمونه‌های تصویری و ویدیو
- بخش ۸: راهنمای رنگ‌های ماسک (فارسی)
- بخش ۹: معیارها و روش ارزیابی
- بخش ۱۰: بحث و محدودیت‌ها
- بخش ۱۱: خروجی‌های تحویل
- بخش ۱۲: جمع‌بندی و نتیجه‌گیری

۳ بیان مسئله و معماری سامانه

۱.۳ چرا ترکیب بینایی واقعی و شبیه‌سازی؟

در جراحی لاپاراسکوپی، سیستم هوشمند باید هم «صحنه را بفهمد» و هم «حرکت هدفمند» انجام دهد. اگر فقط بینایی داشته باشیم، می‌دانیم کبد کجاست اما نمی‌دانیم ابزار را چگونه حرکت دهیم. اگر فقط شبیه‌سازی داشته باشیم، کنترل را می‌آزماییم اما تصویر واقعی نداریم.



دیتاست‌های واقعی مثل CholecSeg8k هزاران فریم با ماسک دقیق دارند؛ ولی action ندارند. شبیه‌سازها مثل action sofa_env و پاداش دارند؛ ولی تصویرشان ساده و مصنوعی است. راه‌حل این پروژه سه‌گانه است: (۱) یادگیری segmentation از واقعیت، (۲) ارزیابی control در شبیه‌ساز امن، (۳) ساخت bridge برای اتصال منطقی دو بخش.

۲.۳ معماری سامانه

DeepLabV3+ → ماسک و داده پردازش → جراحی واقعی فریم

ویدیو و معیار → کنترلر → شبیه‌سازی محیط

Vision Bridge → ارزیابی → شبیه‌سازی + بینایی

شکل ۱: مسیر کلی پروژه از داده تا خروجی

لایه‌های اصلی

- (۱) لایه داده: دانلود، decode ماسک، split ویدیو-محور، dataloader.
- (۲) لایه مدل: DeepLabV3+، loss ترکیبی، معیار mIoU/Dice.
- (۳) لایه شبیه‌سازی: TissueRetractionEnv و کنترلرها.
- (۴) لایه پل: اتصال ویژگی تصویری به کنترلر (synthetic vision).
- (۵) لایه ارزیابی: جمع‌آوری JSON/CSV، نمودار، ویدیو و گزارش.

۳.۳ اهداف و محدوده

- هدف بینایی: آموزش segmentation معنایی روی CholecSeg8k با DeepLabV3+.
- هدف کنترل: ارزیابی retraction در TissueRetractionEnv با کنترلرهای قابل مقایسه.
- هدف اتصال: ساخت Vision Bridge برای مسیر (اکشن → تصویر).
- هدف تحویل: خروجی قابل تکرار؛ معیار، نمودار، تصویر، ویدیو، checkpoint.

چرا این ترکیب؟

دیتاست واقعی action ندارد؛ شبیه‌ساز action دارد اما تصویر واقعی نیست. پروژه هر دو را جدا حل می‌کند و با bridge نشان می‌دهد چطور به هم وصل می‌شوند.



۴.۳ ساختار پوشه‌ها

جدول ۱: نقش پوشه‌های اصلی پروژه

مسیر	نقش
configs/	تنظیمات نهایی (YAML بخش‌بندی و شبیه‌سازی)
src/datasets/	decode ماسک، split ویدیویی، dataloader
src/models/	DeepLabV3+، loss، معیارها
src/sim/	محیط SOFA، کنترلرها، BC، vision bridge
src/train_segmentation.py	آموزش مدل بخش‌بندی
src/eval_segmentation.py	ارزیابی و تولید overlay
outputs/defense_bundle/	تحویل نهایی: checkpoint، معیار، ویدیو
docs/	گزارش PDF و اسلاید دفاع

۴ بخش بینایی ماشین: داده، مدل و نتایج

۱.۴ مجموعه داده CholecSeg8k

دیتاست شامل فریم‌های واقعی جراحی کیسه صفرا (laparoscopic cholecystectomy) است؛ یکی از پرتکرارترین عمل‌های کم‌تهاجمی. هر فریم یک تصویر endoscopic و یک ماسک watershed دارد. ماسک خام مقادیر خاکستری دارد؛ با mask_utils.py به شناسه کلاس 0..12 تبدیل شد.

از نظر بالینی، این ۱۳ کلاس همان چیزهایی هستند که جراح در صحنه می‌بیند: کبد، کیسه صفرا، مجاری، ابزار، خون و غیره. مدلی که این‌ها را تفکیک کند، می‌تواند پایه سیستم هشدار یا راهنمای حرکت باشد.

برای جلوگیری از نشت اطلاعات (data leakage)، تقسیم آموزش/آزمون در سطح ویدیو انجام شد؛ نه فریم. یعنی فریم‌های یک ویدیو یا در آموزش‌اند یا در آزمون، هرگز هر دو. نتیجه: 6240 فریم آموزش، 1840 فریم آزمون (جمع 8080 ماسک).


لینک مجموعه داده

مرجع اصلی: <https://github.com/CAMMA-public/cholecseg8k>

دانلود در پروژه: <https://huggingface.co/datasets/minwoosun/CholecSeg8k>

پیش‌پردازش

(۱) تغییر اندازه به 512×512 . (۲) نرمال‌سازی شدت. (۳) augmentation سبک (چرخش/برش) فقط در آموزش. (۴) batch با collate یکسان برای تصویر و ماسک.



شکل ۲: توزیع پیکسل کلاس‌ها؛ نامتوازن‌ی شدید دلیل وزن‌دهی در تابع هزینه

چرا وزن کلاس لازم بود؟

کلاس‌هایی مثل کبد و پس‌زمینه سهم بسیار بزرگی از پیکسل‌ها دارند؛ گاهی بیش از ۵۰٪ تصویر. اگر مدل فقط این‌ها را درست پیش‌بینی کند، accuracy بالا می‌رود اما mIoU واقعی پایین می‌ماند. بدون class weights، مدل کلاس‌های کوچک (مجاری کیسه صفرا، رگ‌های باریک) را نادیده می‌گیرد. ترکیب cross entropy وزن‌دار و Dice loss برای همین انتخاب شد: یکی جریمهٔ پیکسلی، دیگری همپوشانی ناحیه‌ای.

۲.۴ مدل، آموزش و تنظیمات

مدل DeepLabV3+ با ResNet34 encoder روی تصاویر 512×512 آموزش دید. ASPP (Atrous Spatial Pyramid Pooling) میدان دید چندمقیاسه می‌دهد؛ برای اندام‌های با اندازهٔ مختلف مفید است. decoder مرزهای نرم را بازسازی می‌کند. ResNet34 سبک‌تر از ResNet50 است و برای آموزش عملی مناسب‌تر.

تابع هزینه

$$\mathcal{L} = \mathcal{L}_{CE}^{\text{weighted}} + \mathcal{L}_{Dice}$$

CE وزن‌دار: جریمهٔ بیشتر برای اشتباه در کلاس‌های کم‌نمونه. ضریب **Dice**: همپوشانی ناحیه‌ای؛ برای مرزبندی اندام‌ها مفید است.



جدول ۲: تنظیمات آموزش

پارامتر	مقدار
encoder	resnet34
epochs	۳۰
batch_size	۸
optimizer	Adam
learning_rate	۱e-۴
input_size	۵۱۲×۵۱۲
num_classes	۱۳

قطعه کد کلیدی؛ ساخت مدل


فقط یک تابع مرکزی مدل را می‌سازد؛ تغییر encoder یا تعداد کلاس‌ها کل خط لوله را حفظ می‌کند.

```
def build_model(encoder="resnet34", classes=13):  
    return smp.DeepLabV3Plus(encoder_name=encoder, classes=classes)
```


۳.۴ نتایج segmentation و تحلیل

روی ۱۸۴۰ فریم آزمون (اسپلیت ویدیویی قفل)، بهترین مدل run3_ft:



- mIoU_present: 0.526
- Dice_present: 0.611
- بهترین checkpoint: outputs/defense_bundle/checkpoints/run3_ft/best.pt





شکل ۳: IoU هر کلاس (مرتب شده)؛ کلاس های ساختاری قوی تر، کلاس های کم نمونه ضعیف تر



شکل ۴: رابطه وزن کلاس و فراوانی پیکسل؛ وزن بالاتر برای کلاس های کم نمونه



شکل ۵: چپ: روند loss آموزش؛ راست: روند mIoU/Dice روی آزمون



شکل ۶: چپ: فراوانی پیکسل در برابر IoU؛ راست: Dice در برابر IoU هر کلاس

تحلیل IoU کلاس به کلاس

کلاس‌های بزرگ (کبد، پس‌زمینه، چربی) IoU بالاتر دارند؛ هم فراوانی بیشتر دارند، هم مرزهایشان ضخیم‌تر است. کلاس‌های باریک (مجاری، رگ، رباط) سخت‌ترند: کم‌نمونه، مرز نازک، و گاهی هم‌رنگ با بافت مجاور. $mIoU_{present}=0.526$ با این چالش‌ها نشان‌دهنده یادگیری معنادار است؛ برای کاربرد بالینی روی کلاس‌های حساس (مجاری) هنوز نیاز به بهبود دارد. تفسیر منحنی آموزش: loss در epoch‌های اول سریع کم می‌شود؛ مدل الگوهای درشت را یاد می‌گیرد. mIoU در epoch‌های بعدی آهسته‌تر بالا می‌رود؛ مرزبندی دقیق‌تر زمان می‌برد.

۵ بخش شبیه‌سازی و کنترل رباتیک

۱.۵ محیط، وظیفه و کنترلرها

محیط TissueRetractionEnv در SOFA وظیفه tissue retraction را شبیه‌سازی می‌کند. در جراحی واقعی، جراح گاهی بافت را می‌گیرد و به سمت خاصی می‌کشد تا دید بهتری داشته باشد. در شبیه‌سازی: ابزار باید به نقطه گرفتن برسد، سپس بافت به هدف کشش کشیده شود. هر اپیزود حداکثر 400 گام دارد. پاداش منفی با فاصله تا هدف تعریف شده؛ هرچه دورتر، پاداش بدتر. برخورد اضافی جریمه دارد. موفقیت یعنی بافت به هدف رسیده باشد.



منطق heuristic



در هر گام، بردار حرکت ابزار به سمت هدف (نقطه گرفتن یا مقصد کشش) محاسبه می‌شود. oracle همان منطق را با مختصات واقعی اجرا می‌کند؛ heuristic با تخمین تقریبی. random جهت تصادفی؛ baseline منفی.

کنترلرها:


- **random**: حرکت تصادفی؛ baseline منفی.
- **heuristic**: حرکت هدفمند با مختصات GT.
- **oracle**: همان منطق با سرعت کامل؛ سقف عملکرد.
- **model_vision/synthetic_vision**: تصویر → سرعت (بدون GT؛ بدون سیاست یادگرفته).
- **bc_rgb_v2**: شبکه CNN از RGB به اکشن؛ در زمان تست مختصات هدف ندارد.

جدول ۳: نتایج کنترل TissueRetraction (پروتکل دفاع؛ اعداد قفل)

کنترلر	نرخ موفقیت	پروتکل
oracle	1.000	100×5
heuristic	1.000	100×5
random	0.000	100×5
synthetic_vision	0.000	20×1 slim
model_vision	0.000	20×1 slim
bc_rgb_v2	1.000	40×5



شکل ۷: چپ: مقایسه نرخ موفقیت؛ راست: نمودار راداری نرمال‌شده کنترلرها



شکل ۸: رابطه پاداش و طول اپیزود؛ oracle کوتاه‌تر و پاداش بهتر

تفسیر ویدیوها (بسته دفاع)

control_bc_rgb_v2_success.mp4: مدل کنترل خودمان، فقط RGB، موفقیت کامل.
 control_bc_rgb_v2_success_seed7.mp4 و control_bc_rgb_v2_success_seed53.mp4: همان مدل با موقعیت شروع متفاوت.
 control_oracle_reference_success.mp4: مرجع سقف با state کامل (برای مقایسه).
 DEFENSE_DEMO_REEL_V2.mp4: ریل خلاصه ارائه.

برداشت شبیه‌سازی

سیاست bc_rgb_v2 خودمان بدون مختصات هدف به موفقیت کامل می‌رسد و با سقف oracle هم‌تراز است. روی سیدهای مختلف (شروع متفاوت) نیز پایدار کار می‌کند.

۲.۵ تحلیل رفتار هر کنترلر

heuristic/oracle: مرجع قانون‌محور با دسترسی به state محیط؛ سقف مقایسه.
bc_rgb_v2 (مدل خودمان): از دموهای خبره آموزش دیده؛ در استنتاج فقط RGB می‌بیند، بدون مختصات هدف. روی 200 اپیزود (5 سید) موفقیت کامل و هم‌تراز oracle. ویدیوهای سید 7 و 53 پایداری روی شروع متفاوت را نشان می‌دهند.



۶ اتصال بینایی به کنترل: سیاست یادگرفته خودمان

از تصویر تا اکشن: مدل خودمان

هدف این بخش ساخت مسیر کامل (اکشن → تصمیم → تصویر) با سیاست یادگرفته خودمان است. به جای تکیه بر مختصات مخفی شبیه‌ساز، شبکه مستقیماً از RGB اکشن را پیش‌بینی می‌کند.

۱. ورودی: فریم RGB شبیه‌سازی.

۲. مدل: CNN سیاست bc_rgb_v2 (آموزش دیده از دموهای خبره).

۳. خروجی: سرعت کارت‌زین ابزار، بدون خواندن مختصات هدف محیط.

۴. نتیجه: success=1.000 روی ارزیابی چندسید؛ هم‌تراز سقف oracle.

دست‌آورد کنترل

مدل کنترل خودمان ثابت می‌کند وظیفه retraction را می‌توان فقط با بینایی یادگرفته حل کرد؛ نه فقط با دسترسی کامل به state.

۷ پایپ‌لاین اجرا و پیاده‌سازی

اجرای نهایی پروژه با اسکریپت‌های Python زیر src/ انجام می‌شود (نه یک اسکریپت یکپارچه قدیمی). هر مرحله خروجی مستقل دارد تا در صورت خطا فقط همان مرحله تکرار شود.

جدول ۴: مراحل اجرا و نقاط ورود کد

مرحله	عنوان	گام‌های اصلی / نقطه ورود
۱	داده	دانلود CholecSeg8k؛ decode ماسک (src/datasets/)
۲	آموزش seg	src/train_segmentation.py + best.pt ذخیره: configs/segmentation_run3_ft.yaml
۳	ارزیابی seg	src/eval_segmentation.py روی ۱۸۴۰ فریم؛ mIoU/Dice؛ ویدیوی overlay
۴	کنترل پایه	src/sim/run_env.py با random/heuristic/oracle و ضبط ویدیو
۵	سیاست BC	train_bc.py → collect_bc.py → ارزیابی bc_rgb چندسید
۶	تحويل	بسته outputs/defense_bundle/ (مدل، JSON، ویدیو، ریل دفاع)

نتیجه قفل شده: بخش‌بندی با mIoU_present=0.526، سیاست bc_rgb_v2 با موفقیت کامل، و بسته دفاع آماده ارائه.

دو محیط مجازی


PyTorch: vision، بخش‌بندی، آموزش/ارزیابی BC. sofa/sim: SOFA، فیزیک بافت، اجرای کنترلر. جدا بودن وابستگی‌ها از تداخل نسخه‌ها جلوگیری می‌کند.

بازتولید ارزیابی نهایی در README.md آمده است؛ معیارهای قفل در outputs/defense_bundle/metrics/ ذخیره شده‌اند.


۸ نمونه‌های تصویری، ویدیو و تفسیر بصری

۱.۸ نمونه داده و پیش‌بینی مدل


در این بخش تفاوت داده خام و خروجی مدل روشن می‌شود. فایل‌های sample برای کنترل کیفیت داده‌اند؛ اگر ماسک اشتباه decode شده باشد، کل آموزش بی‌فایده است. فایل‌های overlay خروجی مدل روی آزمون‌اند؛ برای قضاوت کیفی ضروری‌اند چون عدد mIoU به تنهایی نمی‌گوید مدل «کجا» اشتباه می‌کند.



شکل ۹: نمونه‌های ground-truth: تصویر واقعی + ماسک مرجع



شکل ۱۰: خروجی مدل: تصویر، ماسک مرجع و پیش‌بینی در کنار هم




شکل ۱۱: نمونه دیگر overlay؛ خطا بیشتر در کلاس‌های باریک دیده می‌شود

۲.۸ فریم‌های واقعی از ویدیوهای شبیه‌سازی SOFA



فریم‌های زیر مستقیماً از ویدیوهای کنترل در `outputs/defense_bundle/videos/` استخراج شده‌اند (صحنه `TissueRetraction`)؛ نه overlay بخش‌بندی و نه پوستر). برای هر کنترلر، فریم میانه و انتها نشان داده می‌شود.

خواندن فریم‌های ویدیو



فریم میانه: ابزار در مسیر؛ جهت حرکت و فاصله تا هدف. فریم انتها: نزدیک موفقیت یا پایان اپیزود ناموفق. `bc/oracle` معمولاً زودتر به هدف می‌رسند؛ `random` و پل‌های بینایی قدیمی شکست می‌خورند.





شکل ۱۲: مرجع oracle (دسترس‌ی به: state میانه و انتها؛ موفقیت کامل





شکل ۱۳: کنترلر heuristic با مختصات تقریبی: میانه و انتها؛ موفقیت کامل




شکل ۱۴: سیاست خودمان `bc_rgb_v2` (فقط RGB، بدون مختصات هدف): میانه و انتها؛ موفقیت کامل



شکل ۱۵: همان `bc_rgb_v2` روی سید ۷ (موقعیت شروع متفاوت): میانه و انتها



شکل ۱۶: پایه منفی `random`: میانه و انتها؛ شکست (موفقیت صفر)



شکل ۱۷: پل قدیمی (seg model_vision) → centroid → (velocity) میانه و انتها؛ شکست

۹ راهنمای فارسی رنگ‌های ماسک

این بخش برای خواندن تصاویر گزارش ضروری است. در ماسک‌ها و overlayها هر رنگ یک بافت یا ابزار در صحنه جراحی را نشان می‌دهد؛ نه تزیین. توضیحات زیر کاملاً فارسی‌اند.

نحوه رنگ‌آمیزی

در تصاویر ماسک و overlay، هر پیکسل بر اساس شناسه کلاس (0 تا 12) رنگ می‌گیرد. نقشه رنگ از پالت tab20 در matplotlib گرفته شده تا مرز کلاس‌ها در تصویر واضح باشد. جدول زیر معنی هر رنگ را به فارسی توضیح می‌دهد؛ نام انگلیسی کلاس در تصویر نیست؛ فقط معنی پزشکی فارسی.



جدول ۵: فهرست ۱۳ کلاس معنایی (شناسه و معنی فارسی)

شناسه	معنی در جراحی
۰	پس زمینه؛ نواحی بدون بافت مشخص
۱	دیواره شکم
۲	کبد
۳	دستگاه گوارش
۴	چربی
۵	ابزار گیرنده (grasper)
۶	بافت همبند
۷	خون
۸	مجاری کیسه صفرا
۹	قلاب جراحی
۱۰	کیسه صفرا
۱۱	ورید کبدی
۱۲	رباط کبد

جدول ۶: معنی رنگ‌ها در ماسک‌های معنایی

رنگ	معنی در صحنه جراحی
	پس زمینه؛ نواحی تاریک یا خارج از محدوده آناتومیک اصلی؛ معمولاً بیشترین سهم پیکسل
	دیواره شکم؛ لایه صورتی-مایل دیواره؛ مرز محفظه شکمی
	کبد؛ اندام بزرگ قهوه‌ای-قرمز؛ اغلب بیشترین سطح بافت
	دستگاه گوارش؛ روده و لوله گوارشی
	چربی؛ بافت زرد روشن بین اندام‌ها
	ابزار گیرنده؛ نوک فلزی ابزار لاپاراسکوپی
	بافت همبند؛ بافت فیبری سفید بین اندام‌ها
	خون؛ نواحی قرمز تیره؛ خونریزی یا لخته خون
	مجاری کیسه صفرا؛ ساختار لوله‌ای باریک؛ حساس جراحی
	قلاب جراحی؛ ابزار قلاب‌دار فلزی
	کیسه صفرا؛ اندام هدف بسیاری از فریم‌ها
	ورید کبدی؛ رگ‌های آبی-بنفش زیر کبد
	رباط کبد؛ بافت رباطی نگه‌دارنده کبد



نکته تفسیر

در overlay سه تایی، ستون وسط ماسک مرجع (آنچه باید باشد) و ستون راست پیش بینی مدل است. اگر رنگ یک ناحیه در پیش بینی با مرجع یکی باشد، مدل آن کلاس را درست تشخیص داده است. اختلاف رنگ یعنی خطای مرز بندی یا اشتباه کلاس؛ معمولاً در کلاس های باریک و کم نمونه بیشتر دیده می شود.

چطور overlay بخوانیم؟

ستون چپ: تصویر واقعی دوربین. وسط: آنچه برچسب گذار مشخص کرده (مرجع). راست: پیش بینی مدل. هم رنگ = تشخیص درست. اختلاف رنگ = خطای مرز یا کلاس؛ معمولاً کنار مجاری باریک یا سایه شدید.

۱۰ معیارها و روش ارزیابی

معیارهای بینایی

شاخص **IoU** (Intersection over Union)؛ نسبت همپوشانی ناحیه پیش بینی و ناحیه مرجع به اجتماع آن دو.

mIoU میانگین IoU در همه کلاس های معنایی.

ضریب **Dice** برای پیش بینی P و مرجع G :

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|}$$

به نواحی کوچک حساس تر از IoU است. هر دو معیار روی 1840 فریم آزمون محاسبه شدند.

معیارهای شبیه سازی

نرخ موفقیت: درصد اپیزودهایی که بافت به هدف رسید؛ مهم ترین معیار کیفی. میانگین پاداش: جمع پاداش گام ها؛ منفی بیشتر = عملکرد بدتر. طول اپیزود: تعداد گام تا پایان؛ با موفقیت، کوتاه تر یعنی کارآمدتر.

چرا هم عدد هم تصویر؟

در بینایی، mIoU عدد خلاصه است و overlay کیفیت مرزی را نشان می دهد. در کنترل، ویدیو مسیر ابزار را کنار جدول موفقیت می آورد. گزارش هر دو را دارد.



۱۱ بحث و محدودیت‌ها

۱.۱۱ تحلیل طراحی و انتخاب روش

۱.۱.۱۱ دلیل انتخاب DeepLabV3+

معماری encoder-decoder با ASPP برای segmentation پزشکی استاندارد است. DeepLabV3+ نسبت به FCN ساده مرزهای نرم را بهتر حفظ می‌کند. کتابخانه segmentation_models_pytorch امکان تعویض سریع encoder را می‌دهد.

۲.۱.۱۱ دلیل کنترل قانون‌محور

RL نیاز به تعریف پاداش پایدار و داده action زیاد دارد. در این پروژه heuristic/oracle سقف و کف عملکرد را روشن می‌کنند قبل از هر یادگیری پیچیده‌تر.

۲.۱۱ گسترش آینده

- تقویت بیشتر کلاس‌های نادر در بخش‌بندی.
- گسترش سیاست کنترل به وظایف و ظاهرهای متنوع‌تر شبیه‌سازی.
- مسیر بلندمدت: اعتبارسنجی نزدیک‌تر به شرایط اتاق عمل.

۱۲ خروجی‌های تحویل

۱.۱۲ فایل‌های کلیدی

- بسته ارائه: outputs/defense_bundle/
- مدل بخش‌بندی: outputs/defense_bundle/checkpoints/run3_ft/best.pt
- مدل کنترل: outputs/defense_bundle/checkpoints/bc_rgb_v2/best.pt
- ویدیو: random/heuristic/oracle, control_bc_rgb_v2_success*.mp4, DEFENSE_DEMO_REEL_V2.mp4
- معیارهای قفل: outputs/defense_bundle/metrics/
- اسلاید و گزارش: docs/FINAL_REPORT.pdf, docs/DEFENSE_SLIDES_FINAL_ENGLISH.pptx



توضیح ویدیوی demo_segmentation

فریم‌های واقعی با ماسک پیش‌بینی شده روی هم؛ نشان می‌دهد مدل در حرکت دوربین و تغییر نور چطور مرزبندی می‌کند. مکمل اعداد mIoU برای قضاوت کیفی.

۱۳ جمع‌بندی و نتیجه‌گیری

این پروژه مسیر کامل (تحويل → ارزیابی → شبیه‌سازی → بینایی → واقعی داده) را با اعداد و خروجی‌های بصری نشان داده است. در ادامه، یافته‌های اصلی در چهار محور خلاصه می‌شوند.

۱.۱۳ یافته‌های بخش بینایی

بهترین مدل run3_ft با mIoU_present=0.526 و Dice=0.611. کلاس‌های بزرگ قوی‌ترند؛ کلاس‌های کم‌نمونه چالش می‌مانند.

۲.۱۳ یافته‌های بخش کنترل

سیاست bc_rgb_v2 خودمان فقط از RGB به success=1.000 روی 40×5 رسید، هم‌تراز سقف oracle، و روی سیدهای با شروع متفاوت (۷ و ۵۳) پایدار است.

۳.۱۳ یافته‌های مسیر تصویر → اکشن

با Behavior Cloning از دمو خبره، مدل خودمان بدون مختصات هدف در زمان تست کنترل کامل را یاد گرفته است.

۴.۱۳ دستاوردهای کلی

۱. مدل segmentation خودمان روی داده واقعی (run3_ft)

۲. سیاست کنترل یادگرفته خودمان (bc_rgb_v2) با موفقیت کامل

۳. پایپ‌لاین یکپارچه و بسته دفاع آماده ارائه

۴. ویدیوهای چندسید برای پایداری روی شروع متفاوت

جمع‌بندی نهایی

پروژه دو مدل خودمان را تحويل می‌دهد: (۱) بخش‌بندی قوی روی داده واقعی جراحی، (۲) کنترل یادگرفته از RGB بدون مختصات هدف با موفقیت کامل و هم‌تراز oracle. بسته outputs/defense_bundle مبنای ارائه است.



آ ضمیمه: خلاصه معیارها

جدول ۷: جدول یک جای نتایج

مقدار	معیار	بخش
0.526	mIoU_present	بینایی
0.611	Dice	بینایی
0.0	نرخ موفقیت	random
1.0	نرخ موفقیت	heuristic
1.0	نرخ موفقیت	oracle
0.0	نرخ موفقیت	synthetic_vision
0.0	نرخ موفقیت	model_vision
1.000	نرخ موفقیت	bc_rgb_v2

منابع

- [۱] مجموعه داده CholecSeg8k: <https://huggingface.co/datasets/minwoosun/CholecSeg8k>
- [2] CAMMA CholecSeg8k (original): <https://github.com/CAMMA-public/cholecseg8k>
- [3] Chen et al., DeepLabV3+, ECCV 2018.
- [4] <https://www.sofa-framework.org/>
- [5] https://github.com/ScheiklP/sofa_env